강화학습과 시계열 예측을 이용한 알고리즘 트레이딩

# ALGORITHMIC TRADING USING REINFORCEMENT LEARNING AND TIME SERIES PREDICTION

16기 박민규 엄기영 이영노 17기 조성윤

### CONTENT

#### 01. FinRL and Reinforcement Learning

Brief review of FinRL and Reinforcement Learning

#### 02. DLinear Prediction

Explanation of DLinear prediction model

### **03. Prediction Applied Single Model**

Applying prediction dataset into the 'state' of agents

### **04. Ensemble with sharpe ratio**Hard Vote the model with 'highest' sharpe ratio

프로젝트 추진 배경

[Web 발신]

(광고)

쿠빅홀딩스

▶오늘 무슨일이?!?

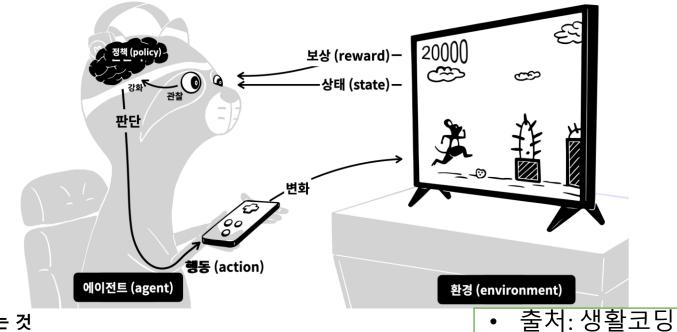
3일 무료방 입장웹

https://github.com/MinkyuRamen/KubigFinancialProject

- ▶ 금융 하면 바로 떠오르는 주식. 시계열 예측으로서는 자주 다루어진 분야
- ▶ 지금까지 전혀 해보지 못했던 도전을 시도해보고자 했음.
- 알고리즘Trading을 강화학습(Reinforcement Learning) 으로 해보자.
- ▶ 쿠빅 최초?

#### WHAT IS REINFORCEMENT LEARNING?

- > 구성: Environment(주변 환경) & Agent (행동의 주체)
- ▶ 학습 방식: 환경과 에이전트 사이의 지속적인 상호작용
- ➤ Data = Trajectory (상호 작용의 결과물)
  - > Environment: State, Reward
  - > Agent: Action



- ➤ Goal: 누적보상(cumulative reward)의 기댓값을 최대화하는 것
- ➤ 목표 달성을 위해 : Policy Improvement

$$\tau = \{S_0, A_0, R_1, S_1, A_1, R_2, S_2, A_2, \dots, \}$$

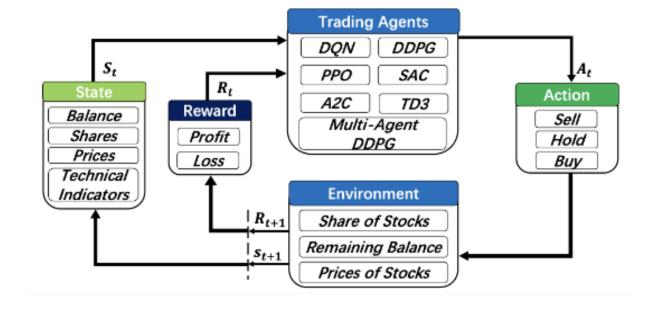
#### **RL IN STOCK MARKETS**

- ➤ Environment: 주식 장 // Agent: 트레이더 -> 어떤 알고리즘이냐에 따라 구분!
- ▶ State: 가격, 각종 지표, 포트폴리오 잔고 현황 등
- ➤ **Action**: 매수, 매도, 유지

 $\{-k, \dots, -1, 0, 1, \dots, k\}$ 

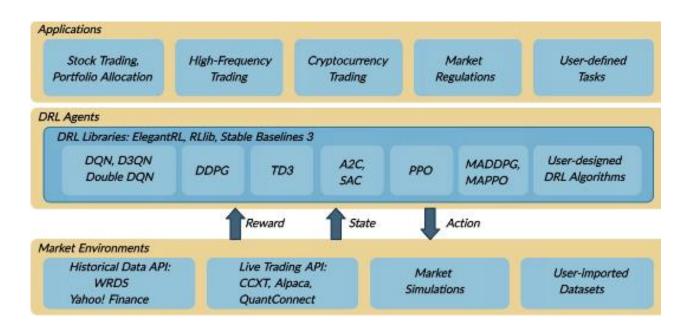
ex) +3 --> 3만큼 주식 portion을 가져간다.

▶ 목표: 포트폴리오의 수익 극대화!



#### **RL IN STOCK MARKETS**





- > Market Environment를 이용해서 DRL Agent 학습 및 여러 application 수행 가능한 패키지
- ▶ 주식 거래, 포트폴리오 최적화, 코인 거래 등 가능.

#### PROBLEM DEFINITION

- ▶ 구현 목표: 해당 포트폴리오의 수익률을 최대화할 수 있는 강화학습 기반의 안정적 장기투자 전략 구현 독창적인 Trading Strategy!
- ➤ 사용된 훈련 데이터셋: 미국 ETF Universe Data Tickers
  \*안정적인 포트폴리오 자산군. 분산투자로 인한 ETF 자산군 간의 낮은 상관계수
- ➤ DLinear + Prediction 정보 추가
- FinRL 기반의 Actor-Critic Multi-agent: A2C, DDPG, PPO, TD3, SAC --> Voting 기반 Ensemble 진행 -> select Best Agent!!
- > TRAIN\_START\_DATE = '2010-01-01' > TRAIN\_END\_DATE = '2021-10-01' > TRADE\_START\_DATE = '2021-10-01' > TRADE\_END\_DATE = '2023-05-03'
- ➤ 성과지표: Maximize Total Reward( & Sharpe Ratio)
- ➤ Benchmark Comparison: 다우존스, 나스닥 주가 지수



$$Maximize: SR_p = \frac{\mu_p - r_f}{\sigma_p} = \frac{\mathbf{w}^T \mathbf{R}}{\sqrt{\mathbf{w}^T \mathbf{\Sigma} \mathbf{w}}}$$

Explanation of DLinear prediction model

## **02. DLINEAR PREDICTION**

#### WHY DO WE NEED DLINEAR?



알고리즘 트레이딩에서 사용되INDICATORS(조지표)

#### 1 INDICATORS

```
['macd',
  'boll_ub',
  'boll_lb',
  'rsi_30',
  'cci_30',
  'dx_30',
  'close_30_sma',
  'close_60_sma']
```

다른 알고리즘 트레이딩 방식들과 마찬가지로,

FinRL Baseline 역시 INDICATORS(보조지표)를 통해 투자 포지션을 결정 (buy/sell/hold) 한다.

- ▶ 하지만 FinRL의 INDICATORS는 macd(이동평균수렴확산), sma(이동평균), rsi(상대강도), boll(볼린저밴드) 등 모두 후행지표밖에 없다.
   (쉽게 말하면 주식가격 결정 이후에 나오는 정보)
- ▶ 현존하는 알고리즘 지표기반 트레이딩의 한계점 중 하나.

Explanation of DLinear prediction model

### **02. DLINEAR PREDICTION**

#### WHY DO WE NEED DLINEAR?

Time Series Forecast SOTA 모델을 이용한 prediction 값을 선행지표로 쓰기로 결정

금융 도메인에선 Nlinear보다 Dlinear의 성능이 보편적으로 우수 > Nlinear가 아닌 Dlinear 선택

Methods		IMP.	Lin	ear*	NLinear*		DLinear*		FEDformer		Autoformer		Informer	
Metric		MSE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE
ity	96	27.40%	0.140	0.237	0.141	0.237	0.140	0.237	0.193	0.308	0.201	0.317	0.274	0.368
tricity	192	23.88%	0.153	0.250	0.154	0.248	0.153	0.249	0.201	<u>0.315</u>	0.222	0.334	0.296	0.386
Elect	336	21.02%	0.169	0.268	0.171	0.265	0.169	0.267	0.214	0.329	0.231	0.338	0.300	0.394
豆	720	17.47%	0.203	0.301	0.210	0.297	0.203	0.301	0.246	0.355	0.254	0.361	0.373	0.439
ge	96	45.27%	0.082	0.207	0.089	0.208	0.081	0.203	0.148	0.278	0.197	0.323	0.847	0.752
lange	192	42.06%	0.167	0.304	0.180	0.300	0.157	0.293	0.271	0.380	0.300	0.369	1.204	0.895
xch	336	33.69%	0.328	0.432	0.331	0.415	0.305	0.414	0.460	0.500	0.509	0.524	1.672	1.036
田田	720	46.19%	0.964	0.750	1.033	0.780	0.643	0.601	<u>1.195</u>	<u>0.841</u>	1.447	0.941	2.478	1.310

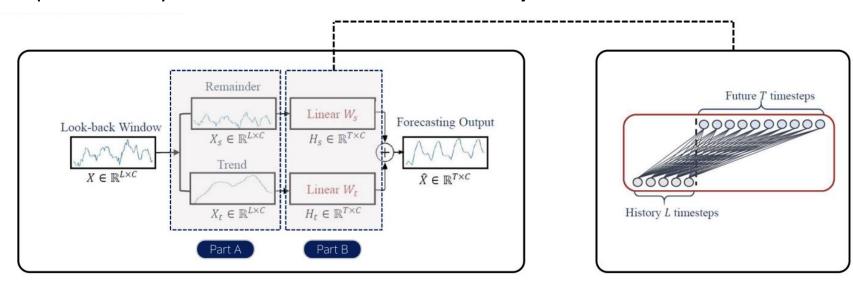
복잡한 Transformer 기반의 Forcasting 모델(Informer, Autoformer, FEDformer) 보다 간단한 Linear-layer 기반의 Forcasting 모델(Nlinear, Dlinear)의 성능이 더 좋다.

### **02. DLINEAR PREDICTION**

#### DLINEAR STRUCTURE

Dlinear 는 크게 Decomposition Part(Part A), layer linear network(Part B) 그리고 Forecasting Output로 나눌 수 있다.

Part A에선 moving average를 활용하여 **trend와 seasonality 로 decompose**, Part B에선 decomposition한 trend와 seasonality에 **1-layer linear network를 apply**, Forecasting output에선 1-layer linear를 거친 **trend와 seasonality를 add**.



Explanation of DLinear prediction model

## **02. DLINEAR PREDICTION**

#### DLINEAR STRUCTURE

Dlinear 의 구조는 매우 단순하기 때문에 메인 코드도 **40줄** 밖에 되지 않는다. 200 epochs를 돌리는데 시간도 **3분** 밖에 소요되지 않는다. -> 알고리즘 트레이딩에 적절

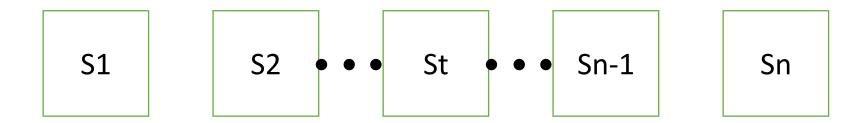
```
27 class LTSF DLinear(torch.nn.Module):
28
29
      def __init__(self, window size, forcast size, kernel size, individual, feature size):
30
           super(LTSF_DLinear, self).__init__()
31
           self.window_size = window_size
32
           self.forcast_size = forcast_size
           self.decompsition = series decomp(kernel size)
           self.individual = individual
           self.channels = feature size
           if self.individual:
37
              self.Linear_Seasonal = torch.nn.ModuleList()
38
               self.Linear Trend = torch.nn.ModuleList()
               for i in range(self.channels):
                   self.Linear Trend.append(torch.nn.Linear(self.window size, self.forcast size))
                   self.Linear Trend[i].weight = torch.nn.Parameter((1/self.window size)*torch.ones([self.forcast size, self.window size]))
42
                   self.Linear_Seasonal.append(torch.nn.Linear(self.window_size, self.forcast_size))
43
                   self.Linear_Seasonal[i].weight = torch.nn.Parameter((1/self.window_size)*torch.ones([self.forcast_size, self.window_size]))
44
45
               self.Linear_Trend = torch.nn.Linear(self.window_size, self.forcast_size)
               self.Linear Trend.weight = torch.nn.Parameter((1/self.window size)*torch.ones([self.forcast size, self.window size]))
               self.Linear Seasonal = torch.nn.Linear(self.window size, self.forcast size)
48
               self.Linear_Seasonal.weight = torch.nn.Parameter((1/self.window_size)*torch.ones([self.forcast_size, self.window_size]))
49
50
      def forward(self, x):
51
           trend_init, seasonal_init = self.decompsition(x)
52
           trend_init, seasonal_init = trend_init.permute(0,2,1), seasonal_init.permute(0,2,1)
53
               trend_output = torch.zeros([trend_init.size(θ), trend_init.size(1), self.forcast_size], dtype=trend_init.dtype).to(trend_init.device)
55
               seasonal_output = torch.zeros([seasonal_init.size(0), seasonal_init.size(1), self.forcast_size], dtype=seasonal_init.dtype).to(seasonal_init.device)
               for idx in range(self.channels):
                   trend_output[:, idx, :] = self.Linear_Trend[idx](trend_init[:, idx, :])
                   seasonal_output[:, idx, :] = self.Linear_Seasonal[idx](seasonal_init[:, idx, :])
59
               trend output = self.Linear Trend(trend init)
               seasonal_output = self.Linear_Seasonal(seasonal_init)
           x = seasonal_output + trend_output
62
           return x.permute(0,2,1)
```

```
1 model = train(model, train loader, criterion, optimizer, device, 200, 1)
              | 1/200 [00:01<04:58, 1.50s/it]Epoch: 1
                                                             Training Loss: 48.150379
 6%¦▮
              | 11/200 [00:15<03:07, 1.01it/s]Epoch: 11
                                                             Training Loss: 186.467575
10%¦■
              | 21/200 [00:24<02:45, 1.08it/s]Epoch: 21
                                                             Training Loss: 163.137222
16%¦■
              | 31/200 [00:34<02:53, 1.03s/it]Epoch: 31
                                                             Training Loss: 121.302902
20% | 1
              41/200 [00:42<02:17, 1.15it/s]Epoch: 41
                                                             Training Loss: 103.253685
              | 51/200 [00:52<02:12, 1.13it/s]Epoch: 51
26%¦
                                                             Training Loss: 105.056389
              61/200 [01:03<02:23, 1.04s/it]Epoch: 61
                                                             Training Loss: 133.377167
              | 71/200 [01:13<02:19, 1.08s/it]Epoch: 71
                                                             Training Loss: 153.780731
              | 81/200 [01:22<01:43, 1.15it/s]Epoch: 81
                                                             Training Loss: 140.970062
              | 91/200 [01:32<01:40, 1.08it/s]Epoch: 91
                                                             Training Loss: 90.491035
              101/200 [01:41<01:38, 1.01it/s]Epoch: 101
                                                             Training Loss: 94.355911
              | 111/200 [01:51<01:26, 1.03it/s]Epoch: 111
                                                             Training Loss: 143.144043
               121/200 [02:00<01:10, 1.12it/s]Epoch: 121
                                                              Training Loss: 110.194191
              | 131/200 [02:10<01:03, 1.09it/s]Epoch: 131
                                                              Training Loss: 110.310150
               141/200 [02:19<01:03, 1.08s/it]Epoch: 141
                                                             Training Loss: 142.625885
               151/200 [02:28<00:43, 1.12it/s]Epoch: 151
                                                              Training Loss: 119.909546
               161/200 [02:38<00:35, 1.09it/s]Epoch: 161
                                                             Training Loss: 112.236832
               171/200 [02:48<00:29, 1.00s/it]Epoch: 171
                                                              Training Loss: 103.230537
               181/200 [02:57<00:17, 1.08it/s]Epoch: 181
                                                             Training Loss: 122.718674
               191/200 [03:06<00:07, 1.13it/s]Epoch: 191
                                                              Training Loss: 139.167847
               200/200 [03:15<00:00, 1.02it/s]
```

#### IDEA OF PREDICTION

강화학습 역시 데이터의 본질은 **시계열성을 띄고 있음**. 즉 **사전관찰** (현재 시점에서 미래의 정보를 확인하는 것)은 **Cheating이 될 수 있으므로 지양**해야.

▶ 그렇다면 어떻게 Prediction Data를 만들고, 각 시점에 집어넣어줄 수 있을까?



#### IDEA OF PREDICTION

• 각 시점의 **1년전 데이터 ~ 현재 데이터를 학습**. EX) 현재 시점 t = 252라면 t = 1 ~ 252 까지의 데이터를 학습.

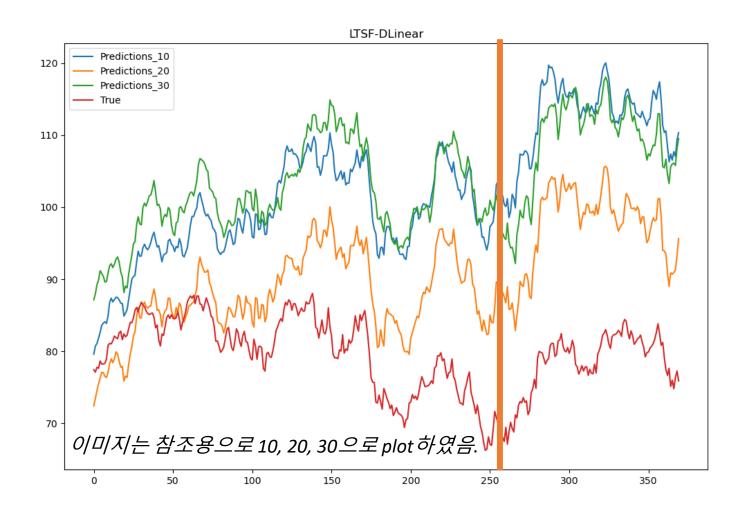
Forecast = 30현시점 기준 • 30일치의 prediction을 당시시점으로 예측. 30시점 뒤까지 EX) t = 252이면 t = 282 까지를 예측. 예측 X1 X252 X282 주식시장의 경우 공휴일과 주말에 **Lookback** = **252** 휴장 -> 252를 1년으로 지정 과거 1년으로 학습

#### PREDICTION RESULT

- 30일 치의 모든 prediction 데이터를 주기에는 어려움이 있음.
- 5, 10, 30 시차 뒤의 prediction만 주기로 결정.

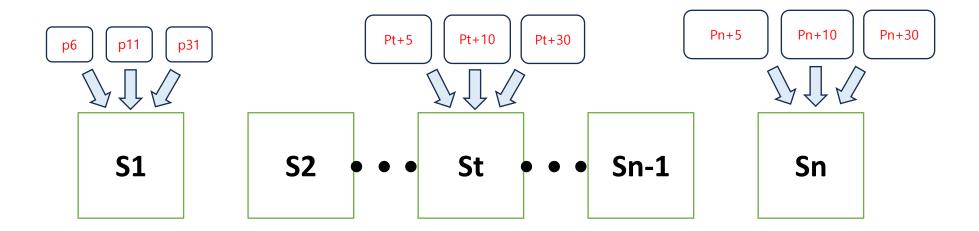
붉은색이 실제 종가, prediction\_n은 해당 시점기준 과거 1년을 통해 학습한 예측모델이 n시점 뒤의 값을 예측한 값.

예를 들어, 오른쪽 테두리친 t = 252 시점의 선에서 predictions\_10은 262번째 시점을 예측한 값.



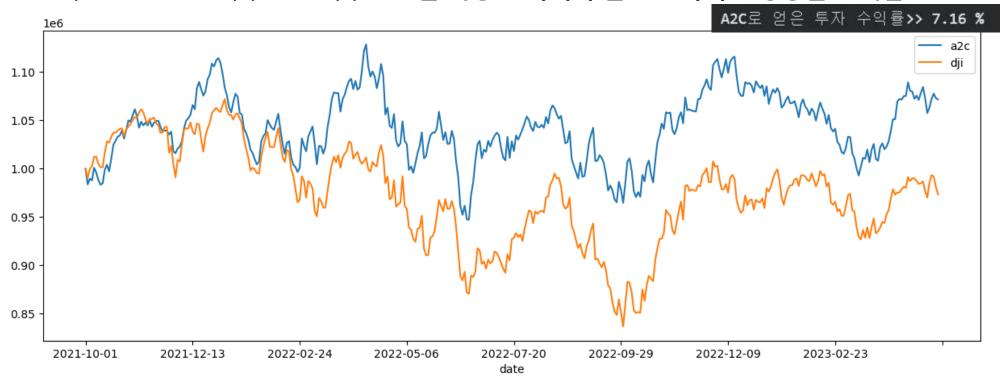
#### APPLYING INTO THE FINRL

강화학습에 입력되는 각 'State'에 5, 10, 30차시의 종가 예측 결과를 추가로 입력.



#### APPLYING INTO THE FINRL

최고 성능을 얻고자함이 아닌, Prediction 데이터 추가가 성능향상에 영향을 주느냐를 분석하기 위함이므로, FinRL, SB3 에서 제공하는 A2C 모델만을 이용해서 실험을 진행. 노란색 그림은 일반 다우존스 지수. A2C를 이용한 거래가 훨씬 효과적인 성능을 보여줌.



#### APPLYING INTO THE FINRL

결과 비교 각각 동일조건에서 Prediction Data를 추가한 경우, 추가하지 않은 경우를 비교. (10회반복)

수익률 -6.43-10.46 2.28 -0.51 9.06 8.84 -0.479.76 -0.60 12.34

With Prediction

평균 수익률>> 2.38 % 표준편차>> 7.13 %



**Without Prediction** 

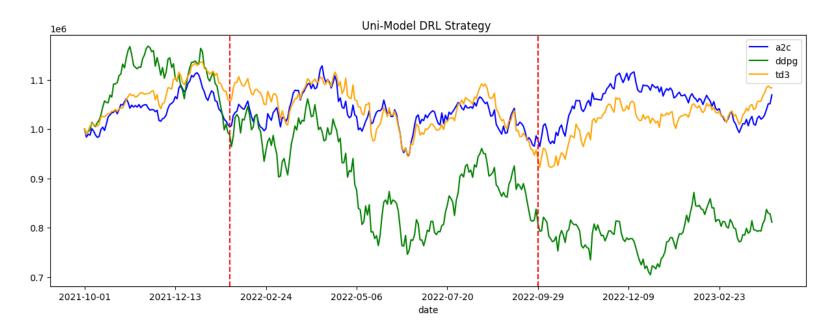
평균 수익률>> -7.15 % 표준편차>> 6.95 %

예측값 이용한 경우의 결과가 우수하게 드러남. 장이 좋지 않았음에도, 꽤나 높은 평균 수익률을 보여주었다.

	수익률
0	-13.42
1	0.10
2	4.20
3	-8.26
4	-1.83
5	-13.84
6	-6.77
7	-11.94
8	-1.17
9	-18.53

#### PROBLEM DEFINITION

- 구간별로 최대 Reward 를 내는 model이 다름.
- 단일 모델의 Reward Volatility high.
- ▶ **구간별로 highest reward model** 을 선택하면, 단일 모델 대비 reward 가 개선되지 않을까 ?
- ➤ High Volatility에 Penalty를 부여할 순 없을까?



- SOLUTION: ENSEMBLE WITH SHARPE RATIO
- 구간별로 최대 Reward 를 내는 model이 다름.
- 단일 모델의 Reward Volatility high.
- ▶ 구간별로 highest reward model 을 hard vote.
- ▶ 안정적 장기투자 관점에서 return volatility에 Penalty. 수익의 급격한 변동을 방지. Risk를 낮추는 전략.

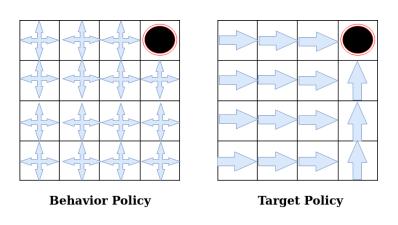
. 1	Iter	Val Start	Val End	Model Used	DDPG Sharpe	SAC Sharpe	TD3 Sharpe
0	126	2021-10-04	2022-01-03	SAC	0.248094	0.413804	0.388397
1	189	2022-01-03	2022-04-04	SAC	-0.348656	-0.125916	-0.282326
2	252	2022-04-04	2022-07-06	SAC	-0.540129	-0.492693	-0.534592
3	315	2022-07-06	2022-10-04	DDPG	0.01164	-0.031788	-0.112318
4	378	2022-10-04	2023-01-04	DDPG	0.08509	-0.121076	-0.081355

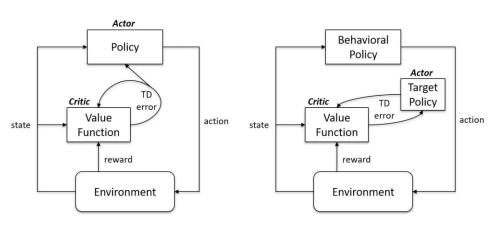
$$S = \left(\frac{R_p - R_f}{\sigma_p}\right)$$

```
if df_total_value["daily_return"].std() != 0:
    sharpe = (
        (252**0.5)
      * df_total_value["daily_return"].mean()
      / df_total_value["daily_return"].std()
)
```

#### 3 STRATEGIES

- Terms
  - Behavioral policy (행동 정책) : Agent 가 action 을 선택할때 사용하는 policy (sampling)
  - Target policy (목표 정책) : 최적의 action function 을 학습하기 위해 update 하는 policy (update)
  - ο **On-Policy**: Behavioral policy = Target Policy Q(s,a') 는 가장 최근 action sampling (a) 에 사용된 behavioral policy π(a'|s) 의 action (a') 으로부터 학습
  - Off-Policy : Behavioral policy ≠ Target Policy
  - ⊙ Q(s,a') 는 target policy π(a'|s) 와 상이한 behavioral policy Ω(a'|s) 으로부터 학습





#### **3 STRATEGIES**

#### All Ensemble

- A2C, PPO, DDPG, SAC, TD3
- 학습 효율성은 저해되지만 최적의 모델 고려 가능

#### On-Policy Algorithms

- A2C, PPO
- Target Policy = Behavioral Policy 에 따른 안정적인 학습 학습과정에서 큰 변동성 X
- Action sampling시 target policy에 따라 데이터 수집하기 때문에 optimal policy 에 더 쉽게 수렴.
- ✓ Exploration 의 제약
- ✓ Action Sampling Bias : 데이터 수집이 현재정책에 의존

#### **Off-Policy Algorithms**

- DDPG, SAC, TD3
- Exploration 을 하면서도
   Optimal Policy Update.
   더 많은 Exploration 보장
- Replay Buffer : Agent가 경험한 데이터를 저장하여 차후 필요할때 sampling
   Sampling Efficiency
- ✓ Convergence
- ✓ 과거 수집 데이터에 의존

#### IMPLEMENTATION

Environment : class StockTradingEnv(gym.env)

```
Agent : class DRLEnsembleAgent()
def DRL_prediction() :
    Action, _states = model.predict(trade_obs)
    Trade_obs, rewards, ... = trade_env.step(action)
# model.predict 으로 Agent 가 선택한 action 반환
# trade_env.step(action) 으로 Environment 에서
# given action 에 대한 next state, reward 반환
```

```
def run_ensemble_strategy_{'OurStrategy'}_:
Train, Validation 진행
Validation: 구간별 sharpe ratio 가 최대인 model 선택
선택된 model 은 다음구간 전략으로 사용됨.
```

```
def DRL_prediction(
    self, model, name, last_state, iter_num, turbulence_threshold, initial
):
    """make a prediction based on trained model"""

trade_obs = trade_env.reset()

for i in range(len(trade_data.index.unique())):
    action, _states = model.predict(trade_obs)
    trade_obs, rewards, dones, info = trade_env.step(action)
    if i == (len(trade_data.index.unique()) - 2):
        # print(env_test.render())
        last_state = trade_env.envs[0].render()

df_last_state = pd.DataFrame({"last_state": last_state})
```

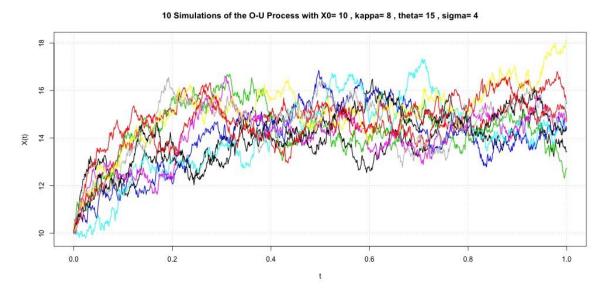
```
# Model Selection based on sharpe ratio

if (sharpe_ddpg >= sharpe_sac) & (sharpe_ddpg >= sharpe_td3):
    model_use.append("DDPG")
    model_ensemble = model_ddpg

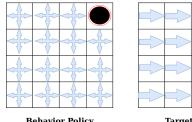
elif (sharpe_sac >= sharpe_ddpg) & (sharpe_sac >= sharpe_td3):
    model_use.append("SAC")
    model_ensemble = model_sac
```

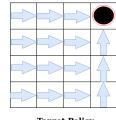
#### ACTION\_NOISE : ORSTEIN\_UHLENBECK PROCESS

- Orstein Ulhenbeck Process (a.k.a. mean-reversion process, Brownian Motion with friction)
- Brownian Motion 의 입자가 마찰(theta) 의 영향을 받아 자신의 이전 상태로 회귀하려는 경향을 가짐. 이러한 경향성이 시간에 따라 심화되면서 long-term mean 으로 회귀하게 되는 확률과정
- 해당 가정은 주식시장에서 과매수/과매도 상황 아래, long-term mean 으로 회귀하려는 특징 반영



$$dX_t = \theta(\mu - X_t)dt + \sigma dW_t$$





WHY OUR PROCESS IN REINFORCEMENT LEARNING?

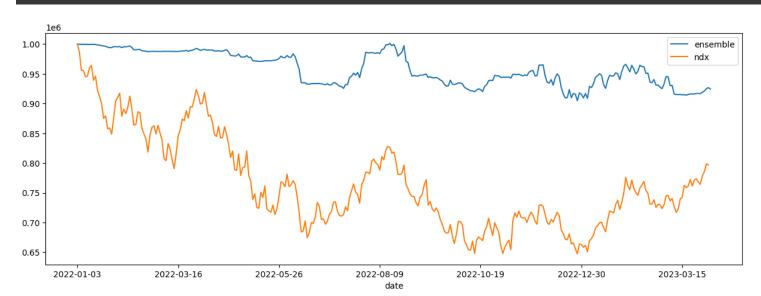
- < 강화학습에 왜 적용되었나?> {'action\_noise': OrnsteinUhlenbeckAct 0.47702929 0.72945688 1.02494153]),
- Off Policy Algorithm 에서 Action Noise 가 Orstein Uhlenbeck Process 를 따른다는 가설.
- 기존 Uniformly random noise를 parametric noise 로 상정하여
  - (1) Statistical Efficiency (충분한 episode가 확보되었을때)
  - (2) precise dynamics
- OU process의 평균회귀 가설은 moving average를 state space로 사용하여 주식시장의 움직임을 capture하고자 하는 DRL모델과 동일한 가설
- 평균회귀 가설이 statistically significant한 경우 움직임을 예측하는데 있어 효과적.

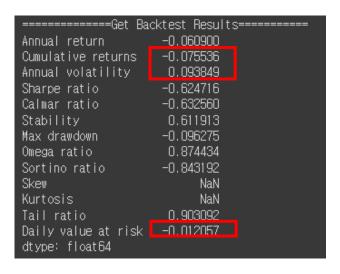


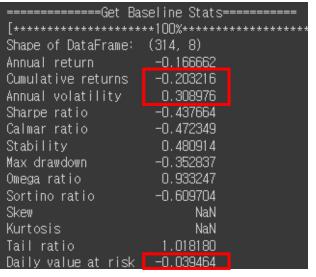
```
model kwargs is None:
   model_kwargs = MODEL_KWARGS[model_name]
   "action_noise" in model_kwargs:
   n_actions = self.env.action_space.shape[-1]
   model_kwargs["action_noise"] = NOISE[model_kwargs["action_noise"]](
       mean=np.zeros(n_actions), sigma= sigma_ * np.ones(n_actions), theta=theta_ * np.ones(n_actions)
print(model_kwargs)
```

#### RESULTS: (1) ALL\_ENSEMBLE

	Iter	Val Start	Val End	Model Used	A2C Sharpe	PPO Sharpe	DDPG Sharpe	SAC Sharpe	TD3 Sharpe
0	126	2021-10-04	2022-01-03	PPO	0.326257	0.583925	0.222091	0.37878	0.319924
1	189	2022-01-03	2022-04-04	SAC	-0.320031	-0.320185	-0.089441	-0.017085	-0.250471
2	252	2022-04-04	2022-07-06	A2C	-0.52318	-0.593024	-0.523324	-0.534957	-0.526993
3	315	2022-07-06	2022-10-04	A2C	0.027793	0.021532	-0.136567	-0.058768	0.014166
4	378	2022-10-04	2023-01-04	SAC	-0.108112	-0.100759	-0.155534	-0.083647	-0.13775

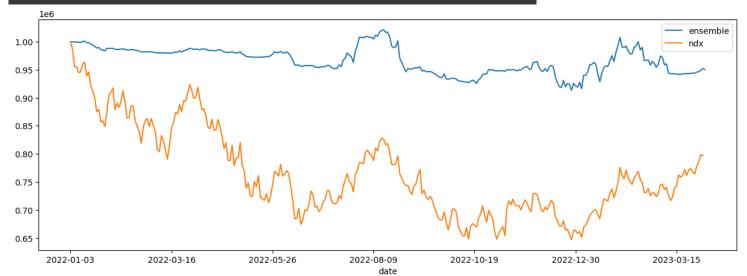






#### RESULTS : (2) ON\_POLICY ENSEMBLE

	Iter	Val Start	Val End	Model Used	A2C Sharpe	PPO Sharpe
0	126	2021-10-04	2022-01-03	PPO	0.278107	0.451536
1	189	2022-01-03	2022-04-04	PPO	-0.244684	-0.215169
2	252	2022-04-04	2022-07-06	A2C	-0.523688	-0.54537
3	315	2022-07-06	2022-10-04	A2C	-0.120781	-0.303323
4	378	2022-10-04	2023-01-04	A2C	-0.086978	-0.187604

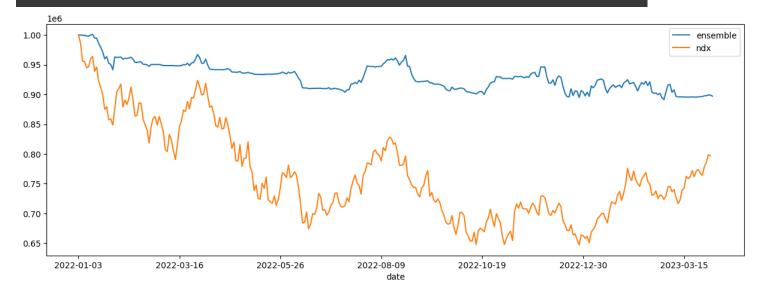


```
========Get Backtest Results=======
Annual return
                     -0.039846
Cumulative returns
                     -0.049557
Annual volatility
                    0.095266
Sharpe ratio
                     -0.380597
Calmar ratio
                     -0.377323
Stability
                      0.327644
                     -0.105602
Max drawdown
                      0.919837
Omega ratio
                     -0.522220
Sortino ratio
Skew
                           NaN
Kurtosis
                           NaN
Tail ratio
                      0.972269
Daily value at risk -0.012146
dtype: float64
```

```
========Get Baseline Stats=======
Shape of DataFrame:
                 (314, 8)
                  -0.166662
Annual return
Cumulative returns
                  -0.203216
Annual volatility
                  0.308976
Sharpe ratio
                  -0.437664
                   -0.472349
Calmar ratio
Stability
                   0.480914
                   -0.352837
Max drawdown
Omega ratio
                   0.933247
                   -0.609704
Sortino ratio
Skew
                       NaN
                       NaN
Kurtosis
Tail ratio
                   1.018180
```

#### RESULTS: (3) OFF\_POLICY ENSEMBLE

	Iter	Val Start	Val End	Model Used	DDPG Sharpe	SAC Sharpe	TD3 Sharpe
0	126	2021-10-04	2022-01-03	SAC	0.248094	0.413804	0.388397
1	189	2022-01-03	2022-04-04	SAC	-0.348656	-0.125916	-0.282326
2	252	2022-04-04	2022-07-06	SAC	-0.540129	-0.492693	-0.534592
3	315	2022-07-06	2022-10-04	DDPG	0.01164	-0.031788	-0.112318
4	378	2022-10-04	2023-01-04	DDPG	0.08509	-0.121076	-0.081355



```
========Get Backtest Results=======
                     -0.083149
Annual return
                    -0.102833
Cumulative returns
Annual volatility
                    0.085803
Sharpe ratio
                     -0.972010
                     -0.759375
Calmar ratio
Stability
                     0.590605
                     -0.109497
Max drawdown
                     0.819928
Omega ratio
Sortino ratio
                     -1.311449
Skew
                           NaN
                           NaN
Kurtosis
Tail ratio
                     0.861816
Daily value at risk -0.011141
dtype: float64
```

```
[***************************
Shape of DataFrame:
                 (314, 8)
                  -0.166662
Annual return
Cumulative returns
                  -0.203216
Annual volatility
                  0.308976
                  -0.437664
Sharpe ratio
Calmar ratio
                  -0.472349
                   0.480914
Stability
                  -0.352837
Max drawdown
Omega ratio
                   0.933247
Sortino ratio
                  -0.609704
Skew
                       NaN
Kurtosis
                       NaN
Tail ratio
                   1.018180
Daily value at risk
```

**RESULTS: 3 STRATEGIES** 

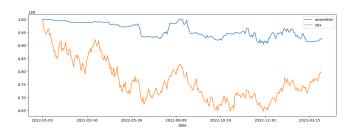
#### All\_Ensemble

A2C, PPO, DDPG, SAC, TD3

• Cumulative Returns: -0.07554

Annual Volatility: 0.093849

• Ensemble took: 356 minutes



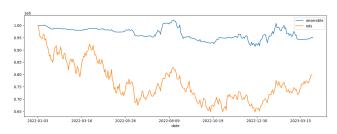
#### **On-Policy Algorithms**

A2C, PPO

Cumulative Returns: -0.04956

• Annual Volatility: 0.095266

• Ensemble took: 78 minutes



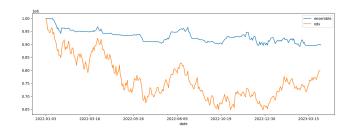
#### **Off-Policy Algorithms**

DDPG, SAC, TD3

Cumulative Returns: -0.10283

Annual Volatility: 0.085803

Ensemble took: 264 minutes



### **CONCLUSION**

#### 의의

- Prediction 으로 강화학습의 성능을 향상시킬 수 있음을 확인
- 스터디에서 쉽게 배우지 못하는 새로운 주제를 할 수 있었음
- Dlinear를 FinRL의 indicator로 추가해보았다.

#### 한계

- XAI 관점에서 투자의사결정 설명이 어려움 (Black Box)
- 파라미터 튜닝 과정에서 모델(Optuna)의 한계로 적용하지 못했음.
- 하이퍼파라미터가 너무 많아 모듈화 간소화가 어려웠음.

